

第十期 ICASSP 2026 论文预讲会听讲报告

ICASSP 2026 论文预讲会【第十期】

INTRODUCTION

- Moving to LLM-base ASR
 - LLMs act as core decoder
 - Encoder - Projector - LLM paradigm
 - SLAM-ASR
 - frozen Encoder & LLM
 - only a simple trainable linear projector
 - monolingual SOTA with low training cost
- Limitations & Challenges
 - Multilingual generalization
 - diverse languages & phonetics
 - requires projector to learn robust cross-lingual acoustic-to-text mapping
 - Modality Alignment
 - typically fixed downsampling
 - lacks explicit alignment

```
graph TD
    User[USER: Transcribe speech to text. ASSISTANT: IT.] -- Speech --> SE[Speech Encoder]
    SE --> DS[Downsampler]
    DS --> LP[Linear Projector]
    LP --> LLM[LLM]
    LLM --> LLM_Tokenizer[LLM Tokenizer]
    LLM_Tokenizer --> LLM
    LLM --> LLM_Decoder[LLM Decoder]
    LLM_Decoder --> Transcript[Transcript]
```

Mu, Z., Yang, G., Yang, Y., Gao, Z., Wang, J., Du, Z., Yu, F., Chen, Q., Zheng, S., Zhang, S., & Chen, X. (2024). An Embarrassingly Simple Approach for LLM with Strong ASR Capacity (arXiv:2402.08846). arXiv: https://doi.org/10.48550/arXiv.2402.08846

林国栋的分享屏幕

主办方: 中国计算机学会 语音与信号专委会 Speech home

林国栋

分享主题:
Enhancing Multilingual LLM-based ASR with Mixture of Experts and Dynamic Downsampling

报告人：王一合

报告日期：2026年5月1日

一、引言

2026年5月，我有幸在线上参加了第十期 ICASSP 2026 论文预讲会

(<https://mp.weixin.qq.com/s/yQkPoh-CnAFWpylOnzrBtA>)。本次预讲会由清华大学SATLab组织，邀请三位青年学者分享三篇已被ICASSP 2026正式录取的高水平论文，主题涵盖大语言模型（LLM）驱动的语音识别、异常声音检测以及工业预测维护等领域。作为一名从事“微调LLM结合多模态数据对齐进行语音情感识别（SER）”方向的研究者，我特别关注LLM在多模态任务中的对齐机制、跨域泛化及架构创新。本次会议内容与我的研究高度契合，为我带来了丰富的方法论启发。

三篇报告各具特色，但其中清华大学SATLab林国栋同学分享的《**Enhancing Multilingual LLM-based ASR with Mixture of Experts and Dynamic Downsampling**》给我留下最为深刻的印象。该论文直击LLM-ASR的核心瓶颈——多语言泛化与模态对齐，其创新思路与我当前SER工作中的多模态对齐策略高度一致。因此，本报告将先概述三篇论文的主要内容，再重点剖析我印象最深的第一篇论文的技术细节、实验结果及对自身研究的启示。

二、报告内容概述

本次预讲会共呈现三篇ICASSP 2026录取论文，从不同维度展现了AI在语音与信号处理领域的最新进展：

1. 林国栋（清华大学SATLab二年级硕士生，研究方向为多语言语音识别）分享的《**Enhancing Multilingual LLM-based ASR with Mixture of Experts and Dynamic Downsampling**》。该论文针对LLM-ASR框架在多语言场景下的泛化不足与模态对齐难

题，提出MoE增强型映射器与CIF动态下采样机制，显著超越Whisper-large-v3等强基线，为高精度、多语言LLM-ASR系统提供了新范式。

2. **梁文锐**（清华大学SATLab二年级硕士生，研究方向为异常声音检测）分享的《**RefGEN: Reference-Guided Synthetic Data Generation for Anomalous Sound Detection**》。论文聚焦工业场景中因域偏移导致的异常声音检测（ASD）数据稀缺问题，提出参考引导的文本到音频（TTA）合成框架RefGEN，通过声学锚点引导生成与BEATs-based语义一致性过滤，生成高质量合成样本，在DCASE 2023数据集上取得72.12%的调和平均数性能，展现了合成数据在低资源场景下的强大潜力。
3. **范俊豪**（密歇根大学工程与计算机学院一年级博士生、清华大学SATLab实习生，研究方向为运筹与优化、AI for Software Engineering）分享的《**SARNet: A Spike-Aware consecutive validation Framework for Accurate Remaining Useful Life Prediction**》。论文针对剩余使用寿命（RUL）预测中脉冲信号易被平滑、缺乏物理解释的问题，提出以ModernTCN为骨干的SARNet框架，引入自适应连续阈值与针对性特征工程，在多个基准数据集上显著降低RMSE和MAE，同时保持模型轻量与可解释性。

三篇论文共同回应了当前语音/信号处理任务的共性挑战：数据稀缺、模态/时序对齐困难以及跨域鲁棒性不足。其中，第一篇论文因其在LLM-ASR Projector设计上的突破性创新，与我正在开展的SER多模态对齐研究高度相关，成为本次听讲的最大收获。

三、重点论文详细解读：《Enhancing Multilingual LLM-based ASR with Mixture of Experts and Dynamic Downsampling》

3.1 论文基本信息

- **标题：**Enhancing Multilingual LLM-based ASR with Mixture of Experts and Dynamic Downsampling
- **作者：**Guodong Lin¹, Ziqi Chen¹, Yuxiang Fu¹, Ke Li², Wei-Qiang Zhang^{1*}（¹清华大学电子工程系，²北京海天瑞声科技有限公司）
- **会议：**ICASSP 2026
- **论文链接：**<https://doi.org/10.1109/ICASSP55912.2026.11464266>

3.2 研究背景与核心问题

LLM-ASR采用Encoder-Projector-LLM范式：语音编码器提取特征，Projector映射至LLM嵌入空间，冻结LLM生成文本。该范式虽简洁高效，但在多语言场景下暴露出两大关键局限：

1. **多语言泛化不足：**单一Projector难以捕捉不同语言的音素与语言模式差异。
2. **模态对齐困难：**语音帧率（50–100 fps）远高于文本token序列，固定下采样对说话速率敏感，易导致信息丢失或长度失配。

论文正是针对这两大痛点展开创新。

3.3 提出方法

（1）MoE-Enhanced Projector

保留基线Projector的卷积共享主干，在线性层引入Mixture of Experts（MoE）架构，专家数

量与训练语言数（11种）匹配。通过门控网络动态路由，输出公式为：

$$[y = \sum_{k=1}^K g_k(x) E_k(x)]$$

其中($g_k(x)$)为门控权重，($E_k(x)$)为专家输出。该设计实现了跨语言自适应映射。

(2) CIF-Based Modality Alignment

引入Continuous Integrate-and-Fire（CIF）替代固定下采样：对每个声学帧赋予权重并累加，累加值超过阈值时“点火”，动态预测token数量并聚合特征。

为缓解标准CIF的过压缩问题，提出**modified CIF**：训练目标调整为生成n倍（实验中n=4）目标token长度的输出，既保留动态对齐优势，又匹配基线下采样率。

两模块协同整合（论文Fig. 1与Fig. 2），大幅提升了Projector的灵活性与对齐精度。

3.4 实验设置与结果

- **骨干模型**：Whisper-large-v3编码器 + Qwen-2.5 7B LLM（冻结）。
- **数据集**：Nexdata 1500小时11语言数据集（英文500小时，其余各100小时）；扩展至8000小时（融合CommonVoice、GigaSpeech2等）。
- **评估**：MLCSLM-dev（域内）、FLEURS-test与CommonVoice-test（域外）。

核心结果（Table 1）显示：

- 基线LLM-ASR（1500h）已劣于Whisper-large-v3。
- 单独MoE Projector将MLCSLM-dev WER从23.26%降至16.10%，语言维度上（Fig. 3）实现全面提升。
- **MoE + modified CIF**在1500h数据上取得最佳性能（MLCSLM-dev 15.27%、CommonVoice-test 13.87%、FLEURS-test 10.46%），全面超越Whisper-large-v3。
- 扩展至8000h后，跨域泛化进一步增强（FLEURS-test 8.65%），验证了大规模数据对鲁棒性的价值。

3.5 主要贡献与创新点

1. 首次将MoE引入LLM-ASR Projector，实现语言自适应的动态路由。
2. 将CIF创新性地用于动态下采样与模态对齐，兼顾效率与鲁棒性。
3. 在多语言ASR上实现显著性能飞跃，证明“Projector设计”是LLM-ASR性能提升的关键突破口。

四、个人感悟与启发

这篇论文给我印象最深的原因在于，其聚焦的“LLM-based多模态对齐”问题与我当前SER工作高度一致：两者均需将连续语音特征精确映射到离散的文本/情感标签序列。我在SER中采用的微调LLM + 多模态对齐策略，也面临项目长度失配与跨域泛化难题。

具体可迁移之处：

- **MoE思路**：可在SER的Projector/Adapter层引入“情感-语言-说话人”维度的MoE专家，实现动态路由，提升跨语言/跨域情感识别能力。

- **CIF动态对齐**：直接迁移至SER的多模态融合模块，用modified CIF替代固定下采样，实现语音、文本、视觉特征的动态长度对齐，避免信息丢失。
- **整体框架启发**：Projector层是LLM微调的“瓶颈”，结合LoRA/Adapter + MoE + CIF的混合设计，有望在低资源SER场景中显著降低训练成本并提升性能。

ASR与SER任务虽有差异（前者侧重识别准确率，后者更关注情感细粒度），但核心对齐思想高度相通。未来我将探索CIF与情感边界检测的结合，或在MoE门控中融入情感先验，进一步优化SER模型。

本次听讲已直接推动我下一阶段实验规划：近期将在当前SER框架中集成MoE-Projector与modified CIF机制，快速验证性能提升。

五、结论与展望

第十期 ICASSP 2026 论文预讲会为我提供了宝贵的前沿视角。三篇论文从LLM-ASR架构优化、合成数据生成到工业RUL预测，共同展现了AI技术在语音与信号处理领域的多元创新路径。其中，第一篇论文在多模态对齐与跨语言泛化上的突破尤其具有启发意义。

通过本次学习，我对LLM-based语音任务的理解更加深刻，也明确了将MoE与CIF等技术快速落地到SER研究的具体路径。感谢主办方精心组织本次预讲会！期待能与三位主讲人面对面交流，也期待将本次收获转化为高质量的研究成果。

参考文献

- [1] Guodong Lin et al. "Enhancing Multilingual LLM-based ASR with Mixture of Experts and Dynamic Downsampling." ICASSP 2026. DOI: 10.1109/ICASSP55912.2026.11464266
- [2] Wenrui Liang et al. "RefGEN: Reference-Guided Synthetic Data Generation for Anomalous Sound Detection." ICASSP 2026. DOI: 10.1109/ICASSP55912.2026.11461896
- [3] Junhao Fan et al. "SARNet: A Spike-Aware consecutive validation Framework for Accurate Remaining Useful Life Prediction." ICASSP 2026. DOI: 10.1109/ICASSP55912.2026.11463499